



(12) 发明专利申请

(10) 申请公布号 CN 122219077 A

(43) 申请公布日 2026. 06. 16

(21) 申请号 202610250996.4

(22) 申请日 2026.03.03

(71) 申请人 中山大学

地址 510275 广东省广州市海珠区新港西路135号

(72) 发明人 朱祥维 刘格陆 王腾 李颂元
吴至杰 伍俊亮 朱钊烨

(74) 专利代理机构 广东雅登驭不凡专利商标代理 事务所（普通合伙）
4401289

专利代理师 赵磊

(51) Int. Cl.

G05B 13/04 (2006.01)


权利要求书2页 说明书10页 附图2页

(54) 发明名称

基于多目标奖励函数的自行车控制策略强化学习训练方法

(57) 摘要

本发明提供了一种基于多目标奖励函数的自行车控制策略强化学习训练方法,包括:构建神经网络控制器,神经网络控制器的输入为观测量,输出为控制量;设计面向平衡与转向控制的多目标奖励函数,多目标奖励函数包括:存活奖励函数、追踪奖励函数和动作平滑度惩罚函数,定义学习目标:寻找一种能够最大化长期累积奖励的控制策略;基于学习目标,在仿真环境中对神经网络控制器进行大规模、高并发的自行车控制并行训练,得到训练完成的神经网络控制器;在仿真环境中对训练完成的神经网络控制器进行全面的性能验证。本发明解决现有技术中传统控制算法对精确数学模型的过度依赖,现代控制算法中又存在复杂耦合动态下目标最优权衡与策略设计困难的问题。



1. 一种基于多目标奖励函数的自行车控制策略强化学习训练方法, 其特征在于, 包括步骤:

构建神经网络控制器, 所述神经网络控制器的输入为观测量, 输出为控制量, 所述观测量是一个包含了描述自行车当前完整状态的综合向量, 所述控制量是所述神经网络控制器在每个决策周期需要输出的控制指令;

设计面向平衡与转向控制的多目标奖励函数, 所述多目标奖励函数包括: 存活奖励函数、追踪奖励函数和动作平滑度惩罚函数, 基于所述多目标奖励函数定义学习目标: 寻找一种能够最大化长期累积奖励的控制策略;

基于所述学习目标, 在仿真环境中对所述神经网络控制器进行大规模、高并发的自行车控制并行训练, 得到训练完成的所述神经网络控制器;

在仿真环境中对训练完成的所述神经网络控制器进行全面的性能验证。

2. 根据权利要求1所述的基于多目标奖励函数的自行车控制策略强化学习训练方法, 其特征在于, 所述观测量包括: 车身侧倾角、侧倾角速度、车身当前线速度、车把当前转角、上一时刻下达的车把转角指令、上一时刻下达的后轮速度指令, 以及当前时刻外部下达的目标线速度指令和目标转向指令; 所述控制量包括: 目标车把转角、目标后轮转速。

3. 根据权利要求1所述的基于多目标奖励函数的自行车控制策略强化学习训练方法, 其特征在于, 存活奖励函数表现为只要仿真环境中的自行车智能体侧倾角在允许范围内, 自行车智能体在每个时间步都会获得一个固定的正向奖励, 激励所述神经网络控制器将自行车智能体“维持不倒”作为优先的任务目标。

4. 根据权利要求3所述的基于多目标奖励函数的自行车控制策略强化学习训练方法, 其特征在于, 所述追踪奖励函数用于引导控制器精确执行外部指令, 所述追踪奖励函数包括:

线速度追踪奖励: 根据自行车当前线速度与指令速度的误差大小给予奖励, 误差越小, 奖励越高; 具体地, 采用指数核函数计算该奖励: $R_{vel} = \exp(-e_{vel}^2 / \sigma_{vel}^2)$, 其中 e_{vel} 是当前线速度与指令线速度的差值,

σ_{vel} 是一个预设的方差参数, 用于控制奖励函数对速度误差的敏感程度, σ_{vel} 越小, 奖励对误差的惩罚越剧烈, 要求追踪的精度越高;

转向追踪奖励: 根据自行车当前路线与目标转向指令的误差大小给予奖励。

5. 根据权利要求4所述的基于多目标奖励函数的自行车控制策略强化学习训练方法, 其特征在于, 转向追踪奖励包括:

全局航向追踪奖励: 若传感器可提供全局航向角, 则直接计算当前航向与指令航向的误差 e_{yaw} , 奖励函数为 $R_{yaw} = \exp(-e_{yaw}^2 / \sigma_{yaw}^2)$, σ_{yaw} 是一个预设的方差参数, 全局航向追踪奖励为最直接的转向控制引导;

倾角追踪奖励: 若仅能获取车身倾角, 通过追踪一个与转向相关的目标倾角来实现间接控制, 直线行驶时为0, 奖励函数为 $R_{roll} = \exp(-e_{roll}^2 / \sigma_{roll}^2)$, 其中 e_{roll} 为当前倾角与目标倾角的误差, σ_{roll} 是一个预设的方差参数;

目标点追踪奖励: 若能获取全局位置, 则设置一系列路径点作为目标, 奖励函数设计为与目标点距离的函数, $R_{pos} = \exp(-d_{target}^2 / \sigma_{pos}^2)$, 其中 d_{target} 为自行车当前位置与目标点的欧氏距离, σ_{pos} 是一个预设的方差参数;

轨迹追踪奖励:若能获取自身历史轨迹,则通过计算车辆与目标轨迹的横向误差(Cross-Track Error, CTE) e_{cte} 来进行更精确的路径控制,奖励函数设计为 $R_{cte} = \exp(-e_{cte}^2 / \sigma_{cte}^2)$, σ_{cte} 是一个预设的方差参数。

6.根据权利要求5所述的基于多目标奖励函数的自行车控制策略强化学习训练方法,其特征在于,动作平滑度惩罚函数包括:

动作幅度惩罚函数:对输出的目标车把转角和目标后轮速度的1范数进行惩罚;

动作速率惩罚函数:对策略输出的动作指令的变化率进行惩罚。

7.根据权利要求6所述的基于多目标奖励函数的自行车控制策略强化学习训练方法,其特征在于,所述神经网络控制器为一个包含3至5层的全连接神经网络。

8.根据权利要求1所述的基于多目标奖励函数的自行车控制策略强化学习训练方法,其特征在于,在仿真环境中对训练完成的所述神经网络控制器进行全面的性能验证,包括步骤:

泛化能力测试:将训练好的所述神经网络控制器部署在多个具有“陌生/未见过”的物理参数,即在训练随机化范围之外,但属于合理范围,包括:不同质量、不同质心位置的自行车模型上,测试平衡与循迹性能,检验对物理模型参数变化的鲁棒性;

抗扰动测试:在仿真中对稳定行驶的自行车施加各种未在训练中显式出现的瞬时或持续性扰动,瞬时或持续性扰动包括:模拟侧向推理、地面凹陷,评估控制策略的抗干扰能力和恢复稳定的速度;

复杂任务测试:在复杂测试地形下向所述神经网络控制器下达连续变化的复杂组合指令,测试执行速度与转向追踪的能力,检验策略在多目标耦合下的综合性能。

9.一种基于多目标奖励函数的自行车控制策略强化学习训练系统,应用了如权利要求1至8中任意一项所述的基于多目标奖励函数的自行车控制策略强化学习训练方法,其特征在于,包括:

神经网络控制器,输入为观测量,输出为控制量,所述观测量是一个包含了描述自行车当前完整状态的综合向量,所述控制量是所述神经网络控制器在每个决策周期需要输出的控制指令;

奖励函数模块,设计有面向平衡与转向控制的多目标奖励函数,所述多目标奖励函数包括:存活奖励函数、追踪奖励函数和动作平滑度惩罚函数,基于所述多目标奖励函数定义学习目标:寻找一种能够最大化长期累积奖励的控制策略;

仿真训练模块,基于所述学习目标,在仿真环境中对所述神经网络控制器进行大规模、高并发的自行车控制并行训练,得到训练完成的所述神经网络控制器;

性能验证模块,在仿真环境中对训练完成的所述神经网络控制器进行全面的性能验证。

基于多目标奖励函数的自行车控制策略强化学习训练方法

技术领域

[0001] 本发明涉及自行车自平衡控制训练技术领域,具体涉及基于多目标奖励函数的自行车控制策略强化学习训练方法。

背景技术

[0002] 自行车的自平衡控制技术按照硬件构型可分为两类:(1)基于飞轮的角动量守恒平衡控制方案(2)基于车把转向的无飞轮平衡控制方案。

[0003] 基于飞轮的角动量守恒平衡控制方案虽然能够实现静态平衡,但其固有缺陷是显著的。为了产生足够的恢复力矩,飞轮系统必须具备相当的质量和极高的转速,这导致其体积大、重量大、功耗大、驱动成本极高,飞轮的高速旋转或频繁启停也会产生持续的噪音与震动;此外飞轮所能提供的恢复力矩受限于飞轮质量有其物理上限,特殊极端情况下可能不足以维持平衡,导致系统鲁棒性不足,抗扰动能力有限。

[0004] 基于车把转向的无飞轮平衡控制方案虽然硬件结构简洁,但其核心瓶颈在于车把转向电机同时承担平衡控制与转向控制两个任务,二者存在强耦合与相互干扰的特性。为了维持平衡,控制器需要频繁对车把进行微调摆动,这会干扰车辆的直线行驶或平滑转向性能;相反,当执行转向指令时,又可能破坏平衡状态,这种内在的矛盾使得传统控制算法的设计变得异常复杂,难以在所有工况下都取得理想的效果。

[0005] 总结而言,在硬件构型方面,基于飞轮的方案因其笨重、高能耗、高驱动成本的固有缺陷而难以得到广泛应用;而硬件简洁的车把转向方案,其平衡与转向的强耦合特性给控制算法的开发与部署带来了巨大的挑战。传统控制算法对精确数学模型的过度依赖,现代控制算法中又存在复杂耦合动态下目标最优权衡与策略设计困难的问题。

发明内容

[0006] 本发明的目的在于克服上述技术不足,提供一种基于多目标奖励函数的自行车控制策略强化学习训练方法,解决现有技术中传统控制算法对精确数学模型的过度依赖,现代控制算法中又存在复杂耦合动态下目标最优权衡与策略设计困难的问题。

[0007] 为达到上述技术目的,第一方面,本发明的技术方案提供一种基于多目标奖励函数的自行车控制策略强化学习训练方法,包括步骤:

[0008] 构建神经网络控制器,所述神经网络控制器的输入为观测量,输出为控制量,所述观测量是一个包含了描述自行车当前完整状态的综合向量,所述控制量是所述神经网络控制器在每个决策周期需要输出的控制指令;

[0009] 设计面向平衡与转向控制的多目标奖励函数,所述多目标奖励函数包括:存活奖励函数、追踪奖励函数和动作平滑度惩罚函数,基于所述多目标奖励函数定义学习目标:寻找一种能够最大化长期累积奖励的控制策略;

[0010] 基于所述学习目标,在仿真环境中对所述神经网络控制器进行大规模、高并发的自行车控制并行训练,得到训练完成的所述神经网络控制器;

[0011] 在仿真环境中对训练完成的所述神经网络控制器进行全面的性能验证。

[0012] 与现有技术相比,本发明的有益效果包括:

[0013] 现代控制算法性能依赖于精确的、经过线性化简化的自行车动力学模型,这种模型建立困难,无法完全描述自行车的强非线性特性,一旦车辆的物理参数与模型参数发生偏差,控制性能便会显著下降,本发明解决了传统控制算法对精确数学模型的过度依赖问题。针对车把转向方案中“平衡”与“转向”任务的深度耦合特性与内在矛盾,本发明技术通过精心设计一个多目标奖励函数,将复杂的控制目标分解为明确的、可量化的优化信号。该奖励函数通过将子目标以一定权重融合成一个标量奖励信号,深度强化学习算法能够在训练中自动地探索和发现能够最大化长期奖励的、高度非线性的复杂控制策略。控制器自主学会在不同状态下如何对平衡、追踪、平滑等多个目标进行最优权衡,输出精准且平滑的控制动作,这种数据驱动的、自动化的策略学习范式,代替了传统方法中耗时耗力的人工建模、参数整定和规则设计,提升了控制策略的性能上限和开发效率。

[0014] 根据本发明的一些实施例,所述观测量包括:车身侧倾角、侧倾角速度、车身当前线速度、车把当前转角、上一时刻下达的车把转角指令、上一时刻下达的后轮速度指令,以及当前时刻外部下达的目标线速度指令和目标转向指令;所述控制量包括:目标车把转角、目标后轮转速。

[0015] 根据本发明的一些实施例,存活奖励函数表现为只要仿真环境中的自行车智能体侧倾角在允许范围内,自行车智能体在每个时间步都会获得一个固定的正向奖励,激励所述神经网络控制器将自行车智能体“维持不倒”作为优先的任务目标。

[0016] 根据本发明的一些实施例,所述追踪奖励函数用于引导控制器精确执行外部指令,所述追踪奖励函数包括:

[0017] 线速度追踪奖励:根据自行车当前线速度与指令速度的误差大小给予奖励,误差越小,奖励越高;具体地,采用指数核函数计算该奖励: $R_{vel} = \exp(-e_{vel}^2 / \sigma_{vel}^2)$,其中 e_{vel} 是当前线速度与指令线速度的差值,

[0018] σ_{vel} 是一个预设的方差参数,用于控制奖励函数对速度误差的敏感程度, σ_{vel} 越小,奖励对误差的惩罚越剧烈,要求追踪的精度越高;

[0019] 转向追踪奖励:根据自行车当前路线与目标转向指令的误差大小给予奖励。

[0020] 根据本发明的一些实施例,转向追踪奖励包括:

[0021] 全局航向追踪奖励:若传感器可提供全局航向角,则直接计算当前航向与指令航向的误差 e_{yaw} ,奖励函数为 $R_{yaw} = \exp(-e_{yaw}^2 / \sigma_{yaw}^2)$, σ_{yaw} 是一个预设的方差参数,全局航向追踪奖励为最直接的转向控制引导;

[0022] 倾角追踪奖励:若仅能获取车身倾角,通过追踪一个与转向相关的目标倾角来实现间接控制,直线行驶时为0,奖励函数为 $R_{roll} = \exp(-e_{roll}^2 / \sigma_{roll}^2)$,其中 e_{roll} 为当前倾角与目标倾角的误差, σ_{roll} 是一个预设的方差参数;

[0023] 目标点追踪奖励:若能获取全局位置,则设置一系列路径点作为目标,奖励函数设计为与目标点距离的函数, $R_{pos} = \exp(-d_{target}^2 / \sigma_{pos}^2)$,其中 d_{target} 为自行车当前位置与目标点的欧氏距离, σ_{pos} 是一个预设的方差参数;

[0024] 轨迹追踪奖励:若能获取自身历史轨迹,则通过计算车辆与目标轨迹的横向误差(Cross-Track Error, CTE) e_{cte} 来进行更精确的路径控制,奖励函数设计为 $R_{cte} =$

$\exp(-e_{cte}^2 / \sigma_{cte}^2)$, σ_{cte} 是一个预设的方差参数。

[0025] 根据本发明的一些实施例,动作平滑度惩罚函数包括:

[0026] 动作幅度惩罚函数:对输出的目标车把转角和目标后轮速度的1范数进行惩罚;

[0027] 动作速率惩罚函数:对策略输出的动作指令的变化率进行惩罚。

[0028] 根据本发明的一些实施例,所述神经网络控制器为一个包含3至5层的全连接神经网络(MLP)。

[0029] 根据本发明的一些实施例,在仿真环境中对训练完成的所述神经网络控制器进行全面的性能验证,包括步骤:

[0030] 泛化能力测试:将训练好的所述神经网络控制器部署在多个具有“陌生/未见过”的物理参数,即在训练随机化范围之外,但属于合理范围,包括:不同质量、不同质心位置的自行车模型上,测试平衡与循迹性能,检验对物理模型参数变化的鲁棒性;

[0031] 抗扰动测试:在仿真中对稳定行驶的自行车施加各种未在训练中显式出现的瞬时或持续性扰动,瞬时或持续性扰动包括:模拟侧向推理、地面凹陷,评估控制策略的抗干扰能力和恢复稳定的速度;

[0032] 复杂任务测试:在复杂测试地形下向所述神经网络控制器下达连续变化的复杂组合指令,测试执行速度与转向追踪的能力,检验策略在多目标耦合下的综合性能。

[0033] 第二方面,本发明提供了一种基于多目标奖励函数的自行车控制策略强化学习训练系统,应用了如第一方面中任意一项所述的基于多目标奖励函数的自行车控制策略强化学习训练方法,包括:

[0034] 神经网络控制器,输入为观测量,输出为控制量,所述观测量是一个包含了描述自行车当前完整状态的综合向量,所述控制量是所述神经网络控制器在每个决策周期需要输出的控制指令;

[0035] 奖励函数模块,设计有面向平衡与转向控制的多目标奖励函数,所述多目标奖励函数包括:存活奖励函数、追踪奖励函数和动作平滑度惩罚函数,基于所述多目标奖励函数定义学习目标:寻找一种能够最大化长期累积奖励的控制策略;

[0036] 仿真训练模块,基于所述学习目标,在仿真环境中对所述神经网络控制器进行大规模、高并发的自行车控制并行训练,得到训练完成的所述神经网络控制器;

[0037] 性能验证模块,在仿真环境中对训练完成的所述神经网络控制器进行全面的性能验证。

[0038] 本发明的附加方面和优点将在下面的描述中部分给出,部分将从下面的描述中变得明显,或通过本发明的实践了解到。

附图说明

[0039] 本发明的上述和/或附加的方面和优点从结合下面附图对实施例的描述中将变得明显和容易理解,其中摘要附图要与说明书附图的其中一幅完全一致:

[0040] 图1为本发明一个实施例提供的基于多目标奖励函数的自行车控制策略强化学习训练方法的流程图;

[0041] 图2为本发明一个实施例提供的面向平衡与转向控制的多目标深度强化学习奖励设计示意图;

[0042] 图3为本发明一个实施例提供的平坦地形自平衡与转向控制仿真测试图;

[0043] 图4为本发明一个实施例提供的复杂地形自平衡与转向控制仿真测试图。

具体实施方式

[0044] 为了使本发明的目的、技术方案及优点更加清楚明白,以下结合附图及实施例,对本发明进行进一步详细说明。应当理解,此处所描述的具体实施例仅仅用以解释本发明,并不用于限定本发明。

[0045] 需要说明的是,虽然在系统示意图中进行了功能模块划分,在流程图中示出了逻辑顺序,但是在某些情况下,可以以不同于系统中的模块划分,或流程图中的顺序执行所示出或描述的步骤。说明书和权利要求书及上述附图中的术语“第一”、“第二”等是用于区别类似的对象,而不必用于描述特定的顺序或先后次序。

[0046] 基于车把转向的无飞轮平衡控制方案虽然硬件结构简洁,但其核心瓶颈在于车把转向电机同时承担平衡控制与转向控制两个任务,二者存在强耦合与相互干扰的特性。为了维持平衡,控制器需要频繁对车把进行微调摆动,这会干扰车辆的直线行驶或平滑转向性能;相反,当执行转向指令时,又可能破坏平衡状态,这种内在的矛盾使得传统控制算法的设计变得异常复杂,难以在所有工况下都取得理想的效果。

[0047] 常见的自平衡控制算法都具有一些缺陷:

[0048] PID控制作为一种线性控制器,其主要缺陷在于参数整定困难且适应性差。PID的三个核心参数通常需要通过大量的人工试错和经验进行整定,过程繁琐且难以达到全局最优。并且自行车作为一个时变、非线性的动态系统,其动力学特性会随着车速、负载、地形的变化而显著改变,一套固定的PID参数难以适应所有工况,存在较大的超调、振荡甚至失稳风险,使得系统的鲁棒性和适应性较差。

[0049] LQR方法的主要瓶颈在于严重依赖精确的数学模型,其要求将复杂的自行车动力学系统线性化,并在该线性模型的基础上进行最优控制。然而,线性化过程本质是一种近似,会损失系统原有的非线性特性,导致控制器在大幅度倾斜或激动等非线性区域性能下降。并且该方法对车辆的质量、质心、轮胎参数等物理属性高度敏感,模型失配将导致控制器性能劣化。此外,标准LQR难以直接处理系统中的物理约束,例如电机最大输出力矩、车把最大转角等,导致安全隐患。

[0050] MPC控制虽然性能强大,具备一定鲁棒性,但是计算量巨大,对硬件要求高。MPC需要在每个控制周期内在线求解一个复杂的优化问题,这对自行车这种动态响应要求较高的系统而言,需要高成本高性能的嵌入式处理器才能满足实时性要求。并且MPC的性能同样依赖于一个精确的预测模型,模型适配问题依然存在。

[0051] 模糊控制的性能完全取决于专家规则库的设计,主观性强且缺乏最优性保证。规则的制定和隶属度函数的调整高度依赖于设计者的经验和直觉,缺乏系统性的设计和优化理论。当系统状态复杂、工况多变时,人力难以覆盖所有情况,制定的规则库可能存在漏洞或不完善之处,导致在某些特定场景下控制失效。此外,当输入变量增多时,模糊规则的数量会呈指数级增长,即“维数灾难”,使得规则库的设计维护变得异常困难,且无法证明其控制策略的稳定性和最优性。

[0052] 滑模控制虽然具备一定鲁棒性,但其固有的“抖振”问题成为其应用于实际物理系

统的主要障碍。理论上,滑模控制通过控制论的高频切换来强制系统状态维持在滑模面上,但在实际中,高频的开关动作会引起执行机构的执行困难,导致系统不稳定,削弱抖振的方法又通常以牺牲系统的鲁棒性和控制精度为代价,难以解决根本矛盾。

[0053] 参照图1至图4,图1为本发明一个实施例提供的基于多目标奖励函数的自行车控制策略强化学习训练方法的流程图;图2为本发明一个实施例提供的面向平衡与转向控制的多目标深度强化学习奖励设计示意图;图3为本发明一个实施例提供的平坦地形自平衡与转向控制仿真测试图;图4为本发明一个实施例提供的复杂地形自平衡与转向控制仿真测试图。

[0054] 在一实施例中,基于多目标奖励函数的自行车控制策略强化学习训练方法,包括步骤:构建神经网络控制器,神经网络控制器的输入为观测量,输出为控制量,观测量是一个包含了描述自行车当前完整状态的综合向量,控制量是神经网络控制器在每个决策周期需要输出的控制指令;设计面向平衡与转向控制的多目标奖励函数,多目标奖励函数包括:存活奖励函数、追踪奖励函数和动作平滑度惩罚函数,基于多目标奖励函数定义学习目标:寻找一种能够最大化长期累积奖励的控制策略;基于学习目标,在仿真环境中对神经网络控制器进行大规模、高并发的自行车控制并行训练,得到训练完成的神经网络控制器;在仿真环境中对训练完成的神经网络控制器进行全面的性能验证。

[0055] 整体技术流程图描述:

[0056] 本专利技术的核心在于通过良好设计的多目标奖励函数(如图2所示),通过大规模的深度强化学习训练,获得一个能够适应复杂动态环境的自行车平衡与转向神经网络控制器,以解决传统控制方法在模型依赖、参数整定、环境适应性等方面的固有缺陷。具体实现如下:

[0057] (1) 基于自行车动力学的观测量与控制量定义

[0058] 本专利方法首先定义神经网络控制器与环境交互所需的信息通道,即观测量(输入)和控制量(输出)。

[0059] 观测量与控制量的定义与自行车的核心动力学原理相耦合:自行车是一个不稳定的非完整约束系统,但可以通过主动控制车把来实现自稳定。其物理原理在于:

[0060] 当车身向某一方向(如左侧)倾倒时,控制器驱动车把向同一方向(左侧)进行快速微调,该动作会改变前轮的触地点,使得整车产生一个向心加速度,地面随之产生一个反向的(等效)离心力作用于车身质心,该离心力会产生一个将车身扶正的恢复力矩,从而抵消倾倒的趋势。同时,通过控制后轮的轮毂电机的转速来提供前进的动力。因此,仅通过协调地控制车把转向和后轮速度,即可实现自行车的平衡维持和方向控制。

[0061] 基于此,本发明技术定义:

[0062] 观测量(状态输入):一个包含了描述自行车当前完整状态的综合向量,具体包括:车身侧倾角、侧倾角速度、车身当前线速度、车把当前转角、上一时刻下达的车把转角指令、上一时刻下达的后轮速度指令,以及当前时刻外部下达的目标线速度指令和目标转向指令。

[0063] 控制量(动作输出):神经网络控制器在每个决策周期需要输出的指令,具体为:目标车把转角、目标后轮(轮毂电机)转速。

[0064] 通过该定义,控制器能够“感知”自身状态和任务目标,并“决定”如何操作执行机

构,形成完整的“感知-决策-执行”闭环。

[0065] (2) 面向平衡与转向控制的多目标奖励函数设计

[0066] 为了引导控制器学会上述复杂的驾驶技能,本专利发明的核心在于一种多目标奖励函数。该函数将抽象的、甚至相互冲突的控制目标,转化为一个具体的、可供强化学习算法优化的标量奖励信号,从而解决了传统方法难以设定最优控制目标和权衡多重任务的难题。本专利方法的奖励函数设计主要包含:

[0067] ①存活奖励(正向奖励):这是最基础的奖励。只要自行车没有倾倒(即侧倾角在允许范围内),自行车智能体在每个时间步都会获得一个固定的正向奖励,该项奖励激励控制器将“维持不倒”作为其优先的任务目标。

[0068] ②追踪奖励(正向奖励):为引导控制器精确执行外部指令,本奖励被设计为两个子项。

[0069] 首先是线速度追踪奖励:根据自行车当前线速度与指令速度的误差大小给予奖励,误差越小,奖励越高。具体地,采用指数核函数计算该奖励: $R_{vel} = \exp(-e_{vel}^2 / \sigma_{vel}^2)$,其中 e_{vel} 是当前线速度与指令线速度的差值, σ_{vel} 是一个预设的方差参数,用于控制奖励函数对速度误差的敏感程度。 σ_{vel} 越小,奖励对误差的惩罚越剧烈,要求追踪的精度越高。

[0070] 其次是转向追踪奖励:该项奖励的设计与车载传感器的配置紧密相关,可采用以下几种备选方案:

[0071] a) 全局航向追踪奖励(默认方案):若传感器(如GPS+IMU融合)可提供全局航向角,则可直接计算当前航向与指令航向的误差 e_{yaw} ,奖励函数为 $R_{yaw} = \exp(-e_{yaw}^2 / \sigma_{yaw}^2)$ 。此为最直接的转向控制引导。

[0072] b) 倾角追踪奖励:若仅能获取车身倾角,可通过追踪一个与转向相关的目标倾角(直线行驶时为0)来实现间接控制。奖励函数为 $R_{roll} = \exp(-e_{roll}^2 / \sigma_{roll}^2)$,其中 e_{roll} 为当前倾角与目标倾角的误差。

[0073] c) 目标点追踪奖励:若能获取全局位置,则可设置一系列路径点作为目标。奖励函数可设计为与目标点距离的函数,例如 $R_{pos} = \exp(-d_{target}^2 / \sigma_{pos}^2)$,其中 d_{target} 为自行车当前位置与目标点的欧氏距离。

[0074] d) 轨迹追踪奖励:若能获取自身历史轨迹,则可通过计算车辆与目标轨迹的横向误差(Cross-Track Error, CTE) e_{cte} 来进行更精确的路径控制。奖励函数可设计为 $R_{cte} = \exp(-e_{cte}^2 / \sigma_{cte}^2)$ 。

[0075] ③动作平滑度惩罚(负向奖励,即惩罚):为避免控制器产生幅度过大的、激烈的、高频的动作决策,鼓励其学习平滑、高效、类似人类的控制方式,该项奖励对过大的或过快的电机控制输出进行惩罚。动作幅度惩罚:对输出的目标车把转角和目标后轮速度的1范数(绝对值)进行惩罚。动作速率惩罚:对策略输出的动作指令的变化率(2范数)进行惩罚。

[0076] 最终的总奖励 R_{total} 是上述各项奖励与惩罚的加权和: $R_{total} = w_{survive} * R_{survive} + w_{track} * R_{track} + w_{action} * R_{action}$ 。其中 $w_{survive}$, w_{track} , w_{action} 分别为各项的权重系数。这些权重系数是重要的超参数,可根据具体的任务需求和实际的训练效果进行调整。例如,在训练初期,可以适当提高 $w_{survive}$ 的权重,引导智能体首先学会最基本的平衡能力;在平衡能力稳定后,再逐步提高 w_{track} 的

权重,来鼓励智能体更好地完成循迹任务。通过调整权重,可以有效引导智能体的学习方向和过程。

[0077] 通过将上述几项奖励与惩罚加权求和专利方法定义了明确的强化学习训练目标:寻找一种能够最大化长期累积奖励的控制策略。该策略必须在“维持平衡不倒”、“准确追踪控制指令”、“节省能量、动作平滑”的多个目标之间做出最有利的动态权衡,从而自主学会最优的自行车自平衡与转向的协同控制方法。

[0078] (3) 控制策略的大规模深度强化学习方针训练

[0079] 在定义学习目标之后,本专利方法采用近端策略优化 (PPO) 的强化学习算法,在仿真环境(如Isaac Sim、ORCA、MuJoCo等)中对神经网络控制器进行大规模、高并发的并行训练。

[0080] 在训练过程中,成千上万个虚拟自行车智能体在各自独立的仿真环境中同时进行探索和试错。它们根据当前状态做出决策,从环境中获取奖励信号,并不断更新自身神经网络的参数,以期获得更高的累计奖励。这种大规模并行的、数据驱动的训练范式显著提升了数据采集和策略训练学习的效率。为确保训练出的控制器具有良好的鲁棒性和泛化能力,能够适应各种复杂环境的不确定性,训练过程中还引入了域随机化策略。

[0081] 本发明中的神经网络控制器在架构上具有灵活性。针对低延迟、高实时性的部署要求,可采用一个包含3至5层的全连接神经网络 (MLP)。该网络结构简单,计算速度快,足以处理包含多个维度的向量化状态输入。作为备选方案,也可以采用更能捕捉时序依赖关系的复杂网络,如循环神经网络或其变体,甚至是Transformer网络,以期在允许更高计算开销的情况下,通过记忆历史状态来获得更优的控制性能。

[0082] (4) 自平衡与转向控制策略仿真验证

[0083] 训练完成后,在仿真环境中对最终得到的神经网络控制器进行全面的性能验证。该步骤旨在脱离物理硬件,纯粹从算法和策略层面检验本发明方法的有效性。验证过程包括:

[0084] ①泛化能力测试:将训练好的控制器部署在多个具有“陌生/未见过”的物理参数的自行车模型上,测试其平衡与循迹性能,检验发明方法对物理模型参数变化的鲁棒性,“陌生/未见过”的物理参数即在训练随机化范围之外,但仍属合理,如不同质量、不同质心位置等。

[0085] ②抗扰动测试:在仿真中对稳定行驶的自行车施加各种未在训练中显式出现的瞬时或持续性扰动,如模拟侧向推理、地面凹陷等,评估控制策略的抗干扰能力和恢复稳定的速度。

[0086] ③复杂任务测试:在复杂测试地形下向控制器下达连续变化的复杂组合指令,如在崎岖不平的地形测试其执行速度与转向追踪的能力,检验策略在多目标耦合下的综合性能。

[0087] 通过上述仿真验证,可以量化评估本方法在各种条件下的稳定性、鲁棒性和适应性,从未证明本发明方法解决了传统控制算法对模型依赖严重、参数整定困难、适应性与泛化能力差等技术问题。

[0088] 针对现有技术在硬件构型和控制算法层面存在的诸多不足,本发明提出了一种基于多目标奖励函数的自行车控制策略强化学习训练方法,旨在解决以下技术问题:

[0089] 1.解决了传统控制算法对精确数学模型的过度依赖问题

[0090] 现有技术中的LQR、MPC等现代控制算法,其性能依赖于精确的、经过线性化简化的自行车动力学模型。这种模型建立困难,无法完全描述自行车的强非线性特性,一旦车辆的物理参数与模型参数发生偏差,控制性能便会显著下降。本专利采用深度强化学习的“无模型(Model-Free)”思想,通过神经网络控制器直接建立从传感器状态输入到执行器指令输出的“端到端”映射。控制器在于高保真物理仿真环境的大量交互中自主学习动力学规律,无需任何预先建立的、精确的数学模型或公式,从根本上摆脱了对模型精确性的要求,解决了因模型失配导致的性能劣化和鲁棒性差的问题。

[0091] 2.解决了复杂耦合动态下目标最优权衡与策略设计困难的问题

[0092] 这是本发明技术的核心,针对车把转向方案中“平衡”与“转向”任务的深度耦合特性与内在矛盾,本发明技术通过精心设计一个多目标奖励函数,将复杂的控制目标分解为明确的、可量化的优化信号。该奖励函数主要包括:

[0093] (1)存活奖励:激励自行车智能体维持不倒,作为最基本的学习目标。

[0094] (2)追踪奖励(线速度追踪与转向追踪):引导自行车智能体精确地跟随外部运动指令,实现特定的运行动作。

[0095] (3)动作平滑度惩罚(动作幅值惩罚与动作速率惩罚):惩罚过大、过快的控制输出,鼓励自行车智能体学习平滑、高效、拟人的控制方式,降低能耗与机械损耗。

[0096] 通过将子目标以一定权重融合成一个标量奖励信号,深度强化学习算法能够在训练中自动地探索和发现能够最大化长期奖励的、高度非线性的复杂控制策略。它自主学会了在不同状态下如何对平衡、追踪、平滑等多个目标进行最优权衡,如高速、低速、转弯、直线等,输出精准且平滑的控制动作,实现了类似熟练骑手般的“丝滑”效果。这种数据驱动的、自动化的策略学习范式,代替了传统方法中耗时耗力的人工建模、参数整定和规则设计,提升了控制策略的性能上限和开发效率。

[0097] 改进后的效果:

[0098] 通过采用本专利所提出的控制策略训练方法,特别是在多目标奖励函数的设计方面,在自行车的自平衡与转向控制方面取得了有益效果:

[0099] 1.实现了自行车平衡与转向任务的最优协同控制和平滑拟人操控

[0100] 这是本发明的核心效果,针对车把转向方案中“维持平衡”和“转向执行”两个任务的强耦合、相互干扰的固有问题,本专利技术通过精心设计的多目标奖励函数,利用深度强化学习算法的全局探索能力,成功训练出能够对两个冲突目标进行最优权衡的控制策略。控制器输出的动作不仅能够准确追踪下达的指令,控制器输出的动作:目标车把角度和车轮转速,而且平滑、高效,有效避免了滑模控制的“抖振”和传统PID控制可能出现的超调与振荡,实现了类似人类骑手般的“丝滑”控制效果。这不仅提升了控制精度和任务执行能力,也降低了机械损耗和系统能耗。

[0101] 2.显著提升了控制策略的开发效率与性能上限

[0102] 本发明提出的“奖励函数设计+强化学习训练”控制器构建范式,从根本上改变了传统控制器的开发流程。它用数据驱动的、自动化的策略学习与优化过程,代替了传统方法中耗时耗力的人工建模、规则设计与参数整定环节。开发者不再需要进行复杂的数学推导或依赖专家经验反复试错,而是将精力聚焦于对高级控制目标的定义上,高级控制目标即

最大化的长久的奖励函数。这种开发范式的转变,不仅将复杂控制策略的研发调试周期从数周缩短至数小时,极大地降低了开发门槛,也使得控制器能够自主学习到超越人类直觉和简单数学规律的高度非线性策略,从而突破了传统算法的性能上限。

[0103] 3.摆脱了对精确数学模型的依赖,增强了策略的适用性

[0104] 本发明采用“无模型”的强化学习思想,控制器通过与环境的直接交互来学习动力学规律,无需任何预先建立的、精确的自行车数学模型。这解决了LQR、MPC等现代控制算法因模型失配而导致性能急剧下降的根本性问题。因此,通过本方法训练出的控制策略天然地对车辆物理参数的轻微变化不敏感,具备了基础的鲁棒性,增强了单一策略在不同个体车辆上的适用性。

[0105] 其中,多目标奖励函数中的存活奖励函数表现为只要仿真环境中的自行车智能体侧倾角在允许范围内,自行车智能体在每个时间步都会获得一个固定的正向奖励,激励神经网络控制器将自行车智能体“维持不倒”作为优先的任务目标。

[0106] 追踪奖励函数用于引导控制器精确执行外部指令,追踪奖励函数包括:线速度追踪奖励:根据自行车当前线速度与指令速度的误差大小给予奖励,误差越小,奖励越高;具体地,采用指数核函数计算该奖励: $R_{vel} = \exp(-e_{vel}^2 / \sigma_{vel}^2)$,其中 e_{vel} 是当前线速度与指令线速度的差值, σ_{vel} 是一个预设的方差参数,用于控制奖励函数对速度误差的敏感程度, σ_{vel} 越小,奖励对误差的惩罚越剧烈,要求追踪的精度越高;转向追踪奖励:根据自行车当前路线与目标转向指令的误差大小给予奖励。

[0107] 转向追踪奖励包括:全局航向追踪奖励:若传感器可提供全局航向角,则直接计算当前航向与指令航向的误差 e_{yaw} ,奖励函数为 $R_{yaw} = \exp(-e_{yaw}^2 / \sigma_{yaw}^2)$, σ_{yaw} 是一个预设的方差参数,全局航向追踪奖励为最直接的转向控制引导;倾角追踪奖励:若仅能获取车身倾角,通过追踪一个与转向相关的目标倾角来实现间接控制,直线行驶时为0,奖励函数为 $R_{roll} = \exp(-e_{roll}^2 / \sigma_{roll}^2)$,其中 e_{roll} 为当前倾角与目标倾角的误差, σ_{roll} 是一个预设的方差参数,用于控制奖励函数对倾角误差的敏感程度;目标点追踪奖励:若能获取全局位置,则设置一系列路径点作为目标,奖励函数设计为与目标点距离的函数, $R_{pos} = \exp(-d_{target}^2 / \sigma_{pos}^2)$,其中 d_{target} 为自行车当前位置与目标点的欧氏距离, σ_{pos} 是一个预设的方差参数,用于控制奖励函数对距离误差的敏感程度;轨迹追踪奖励:若能获取自身历史轨迹,则通过计算车辆与目标轨迹的横向误差(Cross-Track Error, CTE) e_{cte} 来进行更精确的路径控制,奖励函数设计为 $R_{cte} = \exp(-e_{cte}^2 / \sigma_{cte}^2)$, σ_{cte} 是一个预设的方差参数,用于控制奖励函数对路径误差的敏感程度。

[0108] 进一步的,动作平滑度惩罚函数包括:动作幅度惩罚函数:对输出的目标车把转角和目标后轮速度的1范数进行惩罚;动作速率惩罚函数:对策略输出的动作指令的变化率进行惩罚。

[0109] 进一步的,在仿真环境中对训练完成的神经网络控制器进行全面的性能验证,包括步骤:泛化能力测试:将训练好的神经网络控制器部署在多个具有“陌生/未见过”的物理参数,即在训练随机化范围之外,但属于合理范围,包括:不同质量、不同质心位置的自行车模型上,测试平衡与循迹性能,检验对物理模型参数变化的鲁棒性;抗扰动测试:在仿真中对稳定行驶的自行车施加各种未在训练中显式出现的瞬时或持续性扰动,瞬时或持续性扰

动包括:模拟侧向推理、地面凹陷,评估控制策略的抗干扰能力和恢复稳定的速度;复杂任务测试:在复杂测试地形下向神经网络控制器下达连续变化的复杂组合指令,测试执行速度与转向追踪的能力,检验策略在多目标耦合下的综合性能。

[0110] 在一实施例中,基于多目标奖励函数的自行车控制策略强化学习训练系统包括:神经网络控制器,输入为观测量,输出为控制量,观测量是一个包含了描述自行车当前完整状态的综合向量,控制量是神经网络控制器在每个决策周期需要输出的控制指令;奖励函数模块,设计有面向平衡与转向控制的多目标奖励函数,多目标奖励函数包括:存活奖励函数、追踪奖励函数和动作平滑度惩罚函数,基于多目标奖励函数定义学习目标:寻找一种能够最大化长期累积奖励的控制策略;仿真训练模块,基于学习目标,在仿真环境中对神经网络控制器进行大规模、高并发的自行车控制并行训练,得到训练完成的神经网络控制器;性能验证模块,在仿真环境中对训练完成的神经网络控制器进行全面的性能验证。

[0111] 以上是对本发明的较佳实施进行了具体说明,但本发明并不局限于上述实施方式,熟悉本领域的技术人员在不违背本发明精神的前提下还可作出种种的等同变形或替换,这些等同的变形或替换均包含在本发明权利要求所限定的范围内。

[0112] 以上所述本发明的具体实施方式,并不构成对本发明保护范围的限定。任何根据本发明的技术构思所做出的各种其他相应的改变与变形,均应包含在本发明权利要求的保护范围内。




图1




图2



图3



图4